

INFORME TÉCNICO DE COMPETITIVIDAD Y ESTRATEGIA DE TAKEOUT

GOOGLE BIGQUERY VS. DATABRICKS

Análisis comparativo de arquitectura, coste total de propiedad (TCO) y riesgo operativo, con recomendación de takeout de Databricks para la plataforma de datos de Adevinata

Preparado para: Dirección de Ingeniería de Datos y Plataforma — ADEVINTA

Fecha: Julio de 2026

Clasificación: Confidencial — Uso Interno Adevinata

1. RESUMEN EJECUTIVO

Este informe evalúa, desde una perspectiva estrictamente técnica y de arquitectura de sistemas, la idoneidad de Google BigQuery frente a Databricks como motor central de analítica y procesamiento de datos para Adevinata.

Adevinta opera marketplaces digitales de alta transaccionalidad (como Fotocasa, InfoJobs, Coches.net, Habitacalia y leboncoin.fr) con necesidades críticas de analítica de producto, reporting de país, activación de datos para growth, pricing dinámico, detección de fraude y sistemas de recomendación. Gran parte de la infraestructura de Adevinata reside de facto en Google Cloud Platform (GCP). Mantener una infraestructura analítica fragmentada fuera del perímetro nativo de GCP mediante Databricks introduce una capa de coste de red, duplicidad de gobernanza e ineficiencias de ingeniería.

La conclusión técnica de esta evaluación es contundente: para el perfil de carga de trabajo dominante en Adevinata, BigQuery ofrece un menor coste total de propiedad (TCO), una superficie operativa significativamente menor y una predictibilidad de rendimiento muy superior. Databricks, por el contrario, impone una carga operativa estructural (administración de clústeres Spark, tuning de Photon, políticas de Unity Catalog y mantenimiento de tablas Delta Lake) que traslada al equipo de plataforma de Adevinata un coste de ingeniería recurrente que en BigQuery queda completamente absorbido por el proveedor.

Recomendación Estratégica

Se recomienda iniciar un plan de takeout estructurado de Databricks en 3 fases (12–18 meses), consolidando en BigQuery las cargas de BI, reporting, activación de datos y la mayoría de pipelines batch, mientras se evalúa de manera aislada qué cargas de entrenamiento de Deep Learning pesado (ML basado en GPUs) justifican temporalmente un entorno Spark gestionado a corto plazo.

2. CONTEXTO Y ALCANCE EN ADEVINTA

Adevinta se caracteriza por una estructura multi-país y multi-marca. Cada marketplace local requiere agilidad para procesar sus propios datos, pero la dirección de plataforma necesita garantizar un gobierno común, optimizar la facturación (FinOps) y acelerar la democratización del dato.

Dado que el centro de gravedad de la infraestructura y de las herramientas de productividad y analítica de Adevinta se sitúa en GCP, la elección del motor analítico no es neutra: cada componente externo añade latencia de red, complejidad en el IAM federado, silos en el catálogo de datos y costes de salida de datos (egress) invisibles que no aparecen en las comparativas teóricas, pero sí en la factura mensual consolidada de la compañía.

El alcance de este análisis técnico cubre de forma detallada:

- Arquitectura y modelo de ejecución.
- Modelo de costes y TCO real.
- Rendimiento, concurrencia y elasticidad.
- Gobernanza, seguridad y cumplimiento.
- Integración con el ecosistema analítico de GCP (Looker, Vertex AI).
- Operabilidad y coste de atracción/retención de talento.
- Análisis detallado de debilidades técnicas específicas de Databricks.
- Un plan de migración ("Takeout") mitigado por fases.

3. COMPARATIVA ARQUITECTÓNICA PROFUNDA Y MODELO DE EJECUCIÓN

La diferencia fundamental entre ambas plataformas radica en la filosofía de diseño. BigQuery nació como un motor serverless cloud-native multi-tenant que separa de forma absoluta el cómputo del almacenamiento. Databricks es una capa de orquestación y ejecución de Apache Spark montada sobre máquinas virtuales que el cliente debe dimensionar, mantener y optimizar de forma activa.

3.1 Tabla Comparativa de Dimensiones Técnicas

Dimensión Técnica	Google BigQuery	Databricks
Modelo de cómputo	Serverless real, multi-tenant. Asignación dinámica de slots (Dremel).	Clústeres Spark (o SQL Warehouses) basados en VMs que el cliente debe dimensionar y mantener.
Almacenamiento	Columnar optimizado (Capacitor) + Storage API, o formatos abiertos vía BigLake.	Delta Lake sobre almacenamiento en objetos del cliente (S3, GCS, ADLS).
Escalado	Automático e instantáneo a nivel de consulta.	Autoscaling a nivel de clúster, limitado por el tiempo de arranque de nodos (cold start).
Mantenimiento físico	Totalmente automático (compactación de archivos, reclasificación y actualización de metadatos).	Manual/programado por el usuario (VACUUM, OPTIMIZE, Z-ORDER, compactación de small files).
Motor de ejecución	Dremel (motor ANSI SQL masivamente paralelo en C++).	Spark SQL + Photon (motor propietario vectorizado en C++ disponible solo en su SaaS).
Gobernanza	Nativa en Cloud IAM y unificada vía Dataplex de extremo a extremo.	Unity Catalog (capa de abstracción adicional y asíncrona).
Unidad de facturación	Slots asignados (Editions) o bytes escaneados (On-Demand).	Doble coste: DBU (Databricks Units) + Infraestructura de máquinas virtuales del Cloud.

3.2 Diagramas de Arquitectura Comparados



3.3 El Coste del "Operational Toil" (Esfuerzo Operativo) en Adevinta

Para el equipo de ingeniería de plataforma de Adevinta, el uso de Databricks se traduce en ineficiencias y tareas constantes de administración de bajo nivel:

1. Ajuste y Sizing de Clústeres: Decidir si las cargas requieren instancias con GPU, optimizadas para memoria o cómputo, configurar el mínimo y máximo de nodos, y depurar errores de tipo Out Of Memory (OOM) originados por configuraciones erróneas del recolector de basura de Java en Spark.
2. Cold Starts (Arranque en Frío): Un SQL Warehouse o clúster de notebooks inactivo tarda de 2 a 7 minutos en levantar recursos de cómputo físicos cuando llega una consulta nueva. BigQuery ofrece respuesta sub-segundo instantánea gracias a que su pool de slots ya está caliente y compartido a nivel de infraestructura global de Google.
3. Degradación por "Small Files": Delta Lake genera múltiples archivos pequeños si hay streaming o inserciones frecuentes. El equipo técnico debe ejecutar de forma continua comandos manuales OPTIMIZE y VACUUM para evitar que el rendimiento de lectura se desplome. En BigQuery, la compactación y reestructuración física de Capacitor o de las tablas gestionadas en formatos abiertos

se ejecuta de manera totalmente asíncrona, automática y gratuita para el usuario.

4. ESTRATEGIA DE OPEN LAKEHOUSE E INTEROPERABILIDAD DE FORMATOS

Databricks posiciona a Delta Lake como el formato de almacenamiento estándar para Lakehouse. No obstante, esto introduce un bloqueo de proveedor implícito. Databricks promueve Universal Format (UniForm) para simular compatibilidad con Apache Iceberg, pero dicha conversión asíncrona de metadatos añade latencia y requiere configurar Unity Catalog, lo que añade complejidad operativa y posibles fallos de desincronización de metadatos.

4.1 BigQuery Managed Tables for Apache Iceberg (BigLake)

Google BigQuery ofrece un enfoque de arquitectura abierta real a través de BigLake:

- Almacenamiento Único sin Copias: BigQuery puede consultar e incluso escribir directamente sobre datos en formatos abiertos (Apache Iceberg, Delta Lake, Parquet) almacenados en buckets de Google Cloud Storage (GCS) o Amazon S3 sin necesidad de ingesta o movimiento físico de datos.
- Tablas Gestionadas de Iceberg: BigQuery proporciona una integración nativa de lectura y escritura para Apache Iceberg que ofrece el mismo rendimiento y funcionalidades (time travel, índices de metadatos, clustering) que las tablas Capacitor tradicionales, eliminando el bloqueo.
- Separación Real del Motor: Databricks depende de su motor propietario Photon (que no es open source) para lograr un rendimiento de consulta SQL rápido sobre Delta. Si Adevinata decide migrar fuera de Databricks pero mantiene Delta Lake, perderá Photon y experimentará una degradación de rendimiento. BigQuery utiliza el motor Dremel estándar de Google Cloud, garantizando que el dato en formato abierto sea consumible con alto rendimiento por cualquier otra herramienta del ecosistema (como Apache Arrow, Trino o Spark nativo) gracias a la Storage API de BigQuery.

5. MODELO DE COSTES Y ANÁLISIS DE TCO REAL

La optimización de costes (FinOps) es crucial para los marketplaces de Adevinata. Aunque las tarifas nominales por consulta de ambos proveedores puedan parecer competitivas en el papel, el modelo de facturación de Databricks oculta sobrecostes sustanciales.

5.1 Tabla Comparativa de Factores de Coste

Factor de Coste	Google BigQuery	Databricks
Coste en reposo (idle)	Cero. Si no hay consultas activas, no hay facturación de cómputo. Solo se cobra por el almacenamiento físico comprimido.	Alto. Si un clúster o SQL Warehouse se mantiene encendido esperando la siguiente consulta ad-hoc, el consumo de DBUs y VMs continúa.
Previsibilidad	Muy Alta. BigQuery ofrece el modelo de reserva de capacidad (slots) con tarifas fijas predecibles (Editions), ideal para presupuestos corporativos.	Baja. Depende directamente de la disciplina de apagado de clústeres, tagging correcto de recursos y límites de autoscaling configurados manualmente.
Doble Facturación	No. Se paga un único concepto a Google Cloud que cubre el motor serverless completo.	Sí. Se factura la licencia DBU a Databricks, más el coste de las máquinas virtuales y almacenamiento a AWS/GCP.
Tránsito de Red	Cero para cargas dentro de la misma región de GCP.	Variable y elevado. Mover datos entre los buckets de almacenamiento y el "data plane" de Databricks a través de VPCs suele generar costes adicionales de red y transferencia.

5.2 El Coste Oculto de Ingeniería

El coste total de propiedad (TCO) de Databricks para Adevinta debe incluir el coste del personal de ingeniería necesario para su operación: el tiempo dedicado a crear scripts de optimización Delta, configurar y auditar permisos en Unity Catalog, diseñar complejas políticas de clústeres para evitar el sobreaprovisionamiento de VMs por parte de usuarios inexpertos, y solucionar cuellos de botella en Spark. Con BigQuery, estas responsabilidades operativas quedan delegadas en Google Cloud, permitiendo a los ingenieros de Adevinta centrarse en el desarrollo de productos de datos de negocio de alto impacto.

Nota de mercado: Casos reales de migración tecnológica de gran calado, como la compañía logística JB Hunt, documentan reducciones de hasta un 60% en su TCO tras consolidar sus datos en BigQuery, debido a la erradicación del cómputo inactivo y la simplificación de pipelines analíticos complejos.

6. RENDIMIENTO, CONCURRENCIA Y ELASTICIDAD

- Escalabilidad ante ráfagas: BigQuery gestiona picos masivos de concurrencia de forma nativa. Si mil usuarios acceden a Looker simultáneamente un lunes por la mañana para evaluar el rendimiento de InfoJobs o Fotocasa, BigQuery asigna dinámicamente slots adicionales del pool compartido de manera invisible y en milisegundos. Databricks SQL Serverless, aunque ha mejorado respecto a sus clústeres clásicos, sigue requiriendo que los clústeres de ejecución escalen horizontalmente agregando nodos físicos, lo que introduce latencia de aprovisionamiento y colas de espera bajo picos de demanda severos.
- BI Engine: BigQuery cuenta con BI Engine, una capa de análisis en memoria ultrarrápida integrada que optimiza las consultas SQL procedentes de herramientas como Looker o Looker Studio, ofreciendo tiempos de respuesta sub-segundo de forma constante y sin coste de configuración ni gestión de clústeres de caché dedicados.
- Sensibilidad al Data Skew: En Databricks, las consultas complejas con un desequilibrio importante en la distribución de los datos (data skew) pueden saturar nodos Spark específicos, provocando bloqueos y fallos en toda la ejecución si no se realiza un particionamiento o indexado manual extremadamente minucioso. BigQuery redistribuye la carga de forma automática en memoria durante las fases de barajado (shuffling) de la consulta, mitigando el data skew sin necesidad de intervención manual.

7. GOBERNANZA, SEGURIDAD Y CUMPLIMIENTO

Para una multinacional europea como Adevinta, regida por el estricto cumplimiento del RGPD, la distribución del gobierno de datos representa un alto riesgo.

7.1 El Silo de Unity Catalog

Unity Catalog es la solución de Databricks para resolver la fragmentación histórica de sus metastores de Hive. Sin embargo, representa una capa intermedia redundante: para que un servicio nativo de GCP (como Vertex AI) acceda a los datos gobernados por Databricks, el equipo debe configurar conexiones federadas complejas, traductores de tokens y duplicar las políticas de seguridad. Obliga a gestionar permisos de acceso a datos en un catálogo aislado que no se integra de forma directa y fluida con el sistema de políticas de organización de Google Cloud (Cloud IAM).

7.2 Gobierno Centralizado y Nativo con Dataplex

BigQuery hereda la arquitectura de seguridad y permisos de Google Cloud de manera directa y consistente:


- IAM unificado: La misma identidad y grupo de permisos que controla el acceso a las máquinas virtuales o los buckets de GCS en Adevinta controla las consultas y tablas en BigQuery.
- Dataplex (Universal Catalog): Actúa como un plano de control de datos inteligente. Registra, monitorea y unifica metadatos en múltiples almacenes. Proporciona de forma automática e integrada: linaje automático de extremo a extremo (visibilidad completa del dato desde la ingesta en Pub/Sub o Dataflow, pasando por su transformación en BigQuery, hasta su visualización en Looker o consumo por modelos de Vertex AI) y políticas de privacidad robustas (enmascaramiento dinámico de datos sensibles y seguridad granular a nivel de fila y columna).

7.3 Tabla Comparativa de Gobernanza de Datos

Característica de Gobierno	Google Dataplex + IAM	Databricks Unity Catalog
Integración con la Nube	Nativa y consistente. Un único panel de control de acceso en GCP.	Silo secundario. Requiere sincronizar manualmente cuentas e identidades.
Linaje de datos (Lineage)	Captura automática de transformaciones SQL, integrando Looker y herramientas de AI de forma nativa.	Limitado principalmente al código que se ejecuta estrictamente en la infraestructura Spark de Databricks.
Gobernanza de IA	Evaluación y registro unificado de modelos mediante Vertex AI Model Registry integrado.	Requiere mantener e integrar MLflow de forma independiente.
Políticas de Privacidad	Enmascaramiento dinámico de datos y seguridad de fila/columna por IAM nativo.	Configuración de políticas de seguridad dentro de SQL Spark, aisladas de los servicios nativos de nube.

8. INTEGRACIÓN CON EL ECOSISTEMA DE DATOS EXISTENTE

Para una empresa con un alto volumen de sistemas desplegados en Google Cloud como Adevinta, BigQuery no es un almacén de datos aislado: es el centro gravitacional del ecosistema.



La integración es nativa, directa y sin conectores de terceros: 1. BI y Visualización (Looker): La conexión se realiza de forma directa sin costes de transferencia ni parches de red. BI Engine acelera los dashboards del negocio para los equipos locales de cada marketplace de Adevinta con latencias de décimas de segundo. 2. Modelos de Inteligencia Artificial (Vertex AI): Los científicos de datos pueden entrenar y consumir modelos de lenguaje o predictivos en Vertex AI leyendo los datos directamente de BigQuery a través de BigQuery Storage API de alta velocidad, sin necesidad de exportar datos a formatos intermedios ni descargarlos a sistemas de almacenamiento locales.

9. OPERABILIDAD Y COSTE DE TALENTO

La facilidad para contratar, capacitar y retener talento técnico es un factor crítico de negocio. Databricks impone una barrera de entrada técnica sustancialmente mayor que BigQuery.

9.1 Curva de Aprendizaje y Onboarding de Nuevos Ingenieros

- BigQuery: Cualquier desarrollador o analista que domine el lenguaje ANSI SQL estándar puede comenzar a extraer valor en BigQuery desde el primer día. No se requiere comprender arquitecturas distribuidas complejas, ni memoria heap de Java, ni sintonización de hilos Spark. BigQuery ML (BQML) incluso permite entrenar modelos predictivos avanzados mediante sentencias SQL simples, democratizando la analítica predictiva a través de los diferentes países y unidades de negocio de Adevinta.
- Databricks: Exige perfiles con una profunda especialización en Apache Spark, comprensión de la JVM (Java Virtual Machine), optimizaciones de particionado de datos, gestión de notebooks, y el ciclo de desarrollo de MLflow. Este tipo de ingenieros es escaso, altamente cotizado y requiere procesos de onboarding de plataforma largos y costosos.

9.2 Resumen de Requerimientos de Talento por Plataforma

Aspecto Operativo	Google BigQuery	Databricks
Perfil técnico dominante	Analistas, científicos de datos e ingenieros SQL estándar.	Especialistas en Spark, ingenieros de sistemas JVM y DevOps dedicados.
Complejidad de Onboarding	Baja-Media. Centrado exclusivamente en la lógica de negocio y SQL.	Alta. Requiere dominar Spark, parametrización de clústeres y cuadernos interactivos.
Carga de mantenimiento diario	Prácticamente inexistente. Tareas de infraestructura completamente automatizadas por Google.	Continua. Sintonización de políticas de costes, actualización de runtimes y depuración de fallos de memoria en Spark.

10. DEBILIDADES TÉCNICAS ESPECÍFICAS DE DATABRICKS

Un análisis riguroso de Databricks revela importantes debilidades estructurales que afectan directamente la eficiencia técnica de Adevinta:

10.1 Opacidad y Complejidad en la Facturación de DBUs: El coste total de un procesamiento en Databricks está sujeto a una ecuación de tres variables dinámicas: el tipo de instancia cloud de la VM de soporte, el número total de nodos que escalaron en el clúster y el factor multiplicador de DBU que aplica Databricks dependiendo de la categoría del clúster (Jobs, All-Purpose, Serverless, SQL). Predecir o estimar el coste de una consulta o de una carga de trabajo analítica de forma anticipada es sumamente complejo. En BigQuery, se puede estimar el coste exacto de cualquier consulta mediante un simple comando dry-run que indica los bytes exactos a procesar antes de gastar un solo céntimo.

10.2 Limitaciones en el Escalado del Autoscaling de Spark: El sistema de autoscaling de Databricks reacciona ante variaciones de carga en intervalos de minutos. Cuando un dashboard o pipeline requiere procesar datos de manera urgente, debe esperar el tiempo de arranque físico de las nuevas máquinas virtuales añadidas al pool, afectando negativamente el cumplimiento de los Acuerdos de Nivel de Servicio (SLA) de procesamiento. BigQuery escala de forma horizontal y paralela de manera instantánea a nivel de milisegundos, asignando slots de ejecución de su pool elástico global para asimilar la carga.

10.3 Esfuerzo de Mantenimiento Continuo de Delta Lake: Delta Lake no automatiza la compactación física de archivos. En entornos con cargas de streaming continuas o micro-batches frecuentes, el rendimiento de lectura se deteriora drásticamente debido a la acumulación de cientos de miles de archivos pequeños (small files). Si los ingenieros de datos de Adevinta no configuran, programan y vigilan tareas constantes de compactación mediante comandos OPTIMIZE y eliminación de versiones obsoletas vía VACUUM, la velocidad de las consultas decae y la factura de almacenamiento se encarece de manera silenciosa.

10.4 Coexistencia de Gobernanzas en Transición (Unity Catalog vs. Hive): La migración de arquitecturas tradicionales de Databricks basadas en metastores de Hive antiguos hacia el nuevo Unity Catalog representa en sí misma un proyecto complejo e independiente que consume meses de dedicación técnica de ingeniería. Durante dicho periodo de transición, el equipo técnico se ve obligado a convivir con un modelo de gobernanza híbrido y fragmentado, multiplicando las posibilidades de errores de seguridad o brechas en las auditorías de privacidad.

10.5 Dependencia del Runtime Propietario "Photon": El argumento comercial de Databricks se centra en la portabilidad y la naturaleza abierta de su ecosistema. No obstante, el rendimiento ágil de su motor SQL y procesamiento reside en Photon, un motor de ejecución propietario escrito en C++ que no está disponible fuera de la plataforma licenciada de Databricks. Si Adevinta decide migrar sus datos a otra infraestructura pero conservar Delta Lake, experimentará un retroceso de rendimiento considerable, lo que evidencia que la supuesta independencia tecnológica no es real bajo la suite de Databricks.

11. CONSIDERACIONES HONESTAS: ¿DÓNDE SIGUE SIENDO COMPETITIVO DATABRICKS?

Para mantener la rigurosidad técnica y evitar un sesgo injustificado, es crucial reconocer los casos específicos en los que Databricks posee ventajas técnicas reales:

1. Entrenamiento de Modelos de Deep Learning Complejos: Proyectos de Inteligencia Artificial que requieren arquitecturas basadas en PyTorch o TensorFlow a gran escala con un uso intensivo y coordinado de grandes clústeres de GPUs dedicadas. Databricks cuenta con entornos integrados y optimizados para la gestión de este tipo de infraestructuras de computación física.
2. Procesamiento de Datos No Estructurados Muy Heterogéneos: Casos en los que se deben procesar de manera continua datos de vídeo, audio o formatos binarios propietarios mediante código complejo de Python, Scala o C++ antes de estructurar la información analítica.
3. Fuerte Inercia Cultural Spark: En equipos de ingeniería de datos donde la cultura analítica está fuertemente orientada al uso de librerías nativas de Apache Spark, y donde la transición conceptual y técnica hacia el paradigma SQL declarativo de BigQuery implicaría un coste de capacitación elevado a corto plazo.

Análisis de Aplicación en Adevinta: Ninguna de estas excepciones representa el núcleo de la carga analítica que soporta el negocio de Adevinta. El grueso del valor analítico reside en BI multi-país, reporting financiero, segmentación para activación de campañas, y modelos predictivos sobre datos de comportamiento estructurados (como modelos de precio de Coches.net o recomendación de empleo en InfoJobs). Esto valida la estrategia de un takeout enfocado en consolidar el núcleo analítico de la compañía en BigQuery, aislando o minimizando los clústeres de Databricks estrictamente para cargas complejas de Deep Learning si estas existieran.

12. PLAN DE TAKEOUT PROPUESTO EN 3 FASES

Para mitigar riesgos operativos, garantizar la continuidad de negocio de todos los marketplaces de Adevinta y demostrar valor rápido, se propone una hoja de ruta estructurada en un periodo de 12 a 18 meses.

CRONOGRAMA Y FASES DE LA ESTRATEGIA DE TAKEOUT

[FASE 1: Inventario y Quick Wins] -----> Duración: 0 - 4 meses

- * Inventariar exhaustivamente jobs, notebooks y dashboards activos.
- * Clasificar cargas de trabajo según complejidad (BI, ETL, ML pesado).
- * Migrar cargas de BI/Reporting con patrones de consulta intermitentes.
- * Ahorro de TCO inmediato demostrable.

|
v

[FASE 2: Migración de Pipelines Batch] -----> Duración: 4 - 12 meses

- * Reescribir pipelines Spark complejos a SQL declarativo / dbt sobre BigQuery.
- * Configurar BigLake (Apache Iceberg) sobre buckets de almacenamiento actuales.
- * Migrar la gobernanza de datos y mapear permisos de Unity Catalog a Dataplex.

|
v

[FASE 3: Consolidación y Optimización de IA] -----> Duración: 12 - 18 meses

- * Migrar casos de Machine Learning y orquestación MLflow a Vertex AI.
- * Implementar BigQuery ML para scoring batch en SQL directo de producción.
- * Apagado definitivo de workspaces remanentes de Databricks.
- * Consolidar la facturación analítica completa en la cuenta de GCP.

12.1 Guía de Sustitución Tecnológica Directa (Takeout Battlecard)

Componente Databricks	Alternativa Objetivo en GCP	Estrategia Técnica de Sustitución
Databricks SQL Warehouses	BigQuery (Editions / Slots)	Migración directa de la sintaxis SQL. BigQuery asume el escalado dinámico de slots para las consultas concurrentes de Looker sin aprovisionar warehouses fijos.
Notebooks Spark (ETL / Ingestion)	Dataproc Serverless / Cloud Dataflow	Para aquellos pipelines Spark cuya complejidad impida convertirlos en SQL, desplegar Dataproc Serverless. Esto mantiene compatible el código Spark existente pero elimina la administración de clústeres por completo.
Unity Catalog	Dataplex (Universal Catalog) + Cloud IAM	Centralizar las políticas de seguridad, auditorías y linaje de datos de manera uniforme en la infraestructura GCP, unificando los accesos de las marcas locales de Adevinta.
MLflow & Mosaic AI	Vertex AI Platform + BQML	Migrar los experimentos y el registro de modelos de Machine Learning a Vertex AI Model Registry. Utilizar BigQuery ML para entrenar algoritmos analíticos directamente mediante código SQL.
Delta Lake Formats	Apache Iceberg / Tablas Nativas BQ	Configurar accesos directos de BigLake sobre tablas Delta existentes para una transición transparente, y planificar la migración de almacenamiento a Apache Iceberg nativo para maximizar la interoperabilidad del Lakehouse.

12.2 Gestión de Riesgos de la Migración

El principal obstáculo en un proceso de takeout de esta envergadura es la resistencia cultural al cambio por parte de equipos de ingeniería familiarizados con Spark y notebooks. Para contrarrestar este riesgo:

- Involucración temprana: Integrar a los ingenieros de Spark de Adevinta en el codiseño de los equivalentes de BigQuery desde la Fase 1.
- Capacitación en BigQuery Studio: Demostrarles cómo pueden continuar desarrollando en entornos políglotas (Python/SQL) dentro de BigQuery Studio, manteniendo su flexibilidad de codificación pero erradicando las dificultades del mantenimiento operativo del motor de cómputo.

13. CONCLUSIÓN Y RECOMENDACIÓN FINAL

La sustitución técnica de Databricks por Google BigQuery en Adevinta está plenamente justificada. El modelo Serverless real de BigQuery, su capacidad de consulta sobre formatos abiertos con BigLake e Iceberg, la gobernanza automatizada de Dataplex, y su profunda simbiosis con herramientas clave como Looker y Vertex AI representan una evolución competitiva indiscutible.

Las debilidades estructurales de Databricks —complejidad de facturación DBU, cold starts de clústeres, mantenimiento repetitivo de Delta Lake y un catálogo asíncrono secundario— restan capacidad de innovación al equipo de datos de Adevinta al consumir recursos técnicos en tareas puramente administrativas.

Recomendación de acción inmediata:

Se aconseja a la Dirección de Ingeniería de Datos y Plataforma de Adevinta autorizar formalmente el arranque de la Fase 1 de este plan de takeout. Paralelamente, se debe constituir un equipo especializado e interdisciplinar integrado por arquitectos de datos y especialistas en FinOps para cuantificar de manera rigurosa, basados en el consumo real de los últimos 12 meses de Databricks, las eficiencias y el retorno de inversión proyectado con la consolidación en BigQuery.